

研究計画書

正常モード保存型層化コアセットと疎グラフ PatchCore による軽量局
所異常検知

対象研究： オートリベッタ穿孔後の切粉・異物検知

基盤手法： PatchCore / SaikuPatchCore

文書版： v2.0

作成日： 2026 年 8 月 5 日

目次

1	研究テーマ	2
2	背景と研究上の位置づけ	2
3	研究目的	2
4	研究質問と仮説	2
5	提案手法	3
5.1	正常モード保存型層化コアセット	3
5.2	疎グラフ文脈推論	4
6	データセットと分割方針	4
7	評価設計	4
7.1	学術評価	4
7.2	工場導入評価	5
8	比較対象とアブレーション	5
9	成功基準	5
10	研究ロードマップ	5
11	想定される貢献と限界	6

1 研究テーマ

本研究の主題は、オートリベッタ穿孔後画像に含まれる切粉・異物を対象として、正常画像のみから正常分布を構築する PatchCore 系異常検知を高度化することである。特に、同一製品内に存在する明度、反射、ワーク色、撮像系列、設備差などの**正常外観モードの不均衡**と、切粉のような**微小局所異常**を同時に扱う。

提案の中心は、稀だが正常な特徴を memory bank から失わない**正常モード保存型層化コアセット**と、PatchCore が疑わしいと判断した少数パッチのみを関係性に基づいて再評価する**疎グラフ文脈推論**である。最終的には、CPU または低価格 GPU で実用的な判定時間を達成し、KHI の工場導入および金属製品全般への展開を目指す。

本研究が解く問題

通常の global coreset では、多数派の正常特徴が優先され、少数の正常モードが memory bank から失われる可能性がある。また、パッチ単体の最近傍距離だけでは、微小切粉と反射・汚れ・ROI 境界を区別しにくい場合がある。本研究は、同じ計算予算の下で「稀な正常の保護」と「局所関係の利用」を両立する。

2 背景と研究上の位置づけ

PatchCore は、事前学習 CNN から得た正常パッチ特徴を memory bank として保持し、テストパッチとの最近傍距離により異常度を計算する手法である。共有済み SaikuPatchCore 系では、多解像度特徴、FAISS 検索、画像・画素レベル評価を組み合わせしており、metal nut では 256 と 512 の平均融合が高い画素レベル性能を示している。一方、KHI 画像の特徴別評価では、bright 系や一部 grayblack 系などで性能低下が確認され、正常外観の多様性が誤検知に関係する可能性が示唆されている。

近年の研究では、学習データ汚染に対する SoftPatch、long-tail 条件を扱う TailedCore、位置・近傍情報を利用する PNI、高速推論を目的とする EfficientAD などが提案されている。本研究は、製品クラス間ではなく**同一製品内の正常モード不均衡**を明示的に扱い、さらに全パッチではなく上位候補のみへグラフ推論を適用する点に研究上の焦点を置く。

3 研究目的

1. KHI 正常画像に複数の正常モードが存在することを定量的・定性的に確認する。
2. global coreset で少数正常モードの代表特徴が失われる条件を明らかにする。
3. 同じ memory bank 容量において、正常モードを保護する層化コアセットを構築する。
4. PatchCore スコア上位の少数パッチのみを疎グラフで再評価し、微小切粉の局在性能を改善する。
5. 精度、誤検知率、判定時間、RAM、memory bank 容量の Pareto 改善を評価する。
6. KHI #6, KHI #7, 公開金属データセットで再現性と一般化可能性を検証する。

4 研究質問と仮説

ID	研究質問	検証仮説
RQ1	同一製品内に複数の正常モードが存在するか	明度, 反射, 設備, 撮影系列, 位置等に対応した複数モードが, 画像統計と特徴空間の両方で確認できる.
RQ2	global coreset で少数モードが失われるか	全体頻度が低いモードほど prototype coverage が低下し, そのモードの正常画像 FPR が上昇する.
RQ3	層化 coreset は誤検知を減らせるか	同じ bank 容量で worst-mode FPR と FP/1000 good を低減し, chip Recall を維持する.
RQ4	疎 graph は局在を改善するか	PatchCore 上位パッチのみの graph 再評価により Pixel AP または AUPRO が改善し, 追加時間は総推論時間の 20% 以内となる.
RQ5	両手法は相乗効果を持つか	層化 coreset と疎 graph の統合が, 精度・速度・容量の Pareto front 上で baseline より優れる.
RQ6	金属製品へ一般化できるか	同一の層化・graph 規則を用い, 製品ごとに正常 bank のみを再構築することで複数金属カテゴリへ適用できる.

5 提案手法




図 1: 提案する正常モード保存型層化コアセット・疎グラフ PatchCore の全体像

5.1 正常モード保存型層化コアセット

正常モードは, 明示属性と潜在特徴を組み合わせて定義する. 明示属性には machine ID, 明度クラス, ワーク色, 撮像系列, 半径区間, 角度区間を用いる. 潜在モードには正常特徴を PCA または IPCA で圧縮した後のクラスターを用いる. 異常画像と GT はモード定義へ使用しない.

モード c の画像数または patch 数を n_c , 総 bank 予算を B , 最低保証数を $b_{\min}$ とすると, 初期候補として次の最低保証付き平方根割当を検証する.

$$B_c = b_{\min} + (B - Cb_{\min}) \frac{\sqrt{n_c}}{\sum_{j=1}^C \sqrt{n_j}}. \quad (1)$$

各モード内で greedy coreset を実行し, 最終的に全モードの prototype を結合する. 比例, 均等, 平方

根, 最低保証付き比例を比較対象とする.

5.2 疎グラフ文脈推論

テスト画像の全パッチへ GNN を適用すると, 計算量と平滑化の危険が大きい. そこで, 第 1 段階で PatchCore スコアを計算し, 上位 M パッチまたは上位 $q\%$ のパッチだけを query node とする. 各 query node を近傍 prototype, 空間近傍, 極座標近傍へ接続する.

最終パッチスコアは, 特徴距離 d_i^{PC} , graph 不整合度 d_i^{G} , 正常モード内距離 d_i^{mode} を用いて次の形で構成する.

$$s_i = \alpha d_i^{\text{PC}} + \beta d_i^{\text{G}} + \gamma d_i^{\text{mode}}. \quad (2)$$

初期段階では学習不要の graph Laplacian, 次に 1 層 GraphSAGE, 最後に GAT を比較する.

6 データセットと分割方針

表 2: 主要データセットの役割

データセット	主目的	分割原則	主な評価
KHI #6	主対象・設備内 評価	撮影系列・ワーク単位	Image/Pixel 指標, mode 別 FPR, 速度
KHI #7	主対象・設備差 評価	撮影系列・ワーク単位	#6 との相互転移, FP/FN 事例
MVTec AD 2 金属系	難条件・照明 変動	公式分割	AUPRO, Pixel AP, 速度
MPDD	金属製品一般化	公式または group-aware	カテゴリ別性能, 容量
MVTec AD 金属系	既存研究比較	公式分割	Image/Pixel AUROC, AP

train good は特徴抽出器の固定 forward, reducer fit, normal mode 推定, memory bank 構築にのみ使用する. validation good/chip は閾値校正とハイパーパラメータ選択に使用する. 最終 test は条件確定後に一度だけ評価する. 同一撮像系列や重複画像の train/test 混入を禁止する.

7 評価設計

7.1 学術評価

- 画像レベル: Image AUROC, Image AP, Recall at fixed FPR, FP/1000 good.
- 画素レベル: Pixel AUROC, Pixel AP, AUPRO, IoU, Dice, Localization Hit Rate.
- モード頑健性: mode 別 FPR, worst-mode FPR, rare-mode FPR, prototype coverage.

- 統計：主要条件 3 seed 以上, bootstrap 95% 信頼区間, カテゴリ別・異常サイズ別結果.

7.2 工場導入評価

end-to-end の p50, p95, p99 時間を測定し, 画像読み込み, 前処理, CNN, 次元削減, ANN 検索, graph 構築, GNN, 保存へ分解する. 最大 CPU RAM, 最大 GPU メモリ, モデル容量, memory bank 容量, index 容量, 起動時間, 連続 1000 枚処理時の失敗率を記録する.

8 比較対象とアブレーション

表 3: 必須アブレーション

条件	層化 coreset	graph 文脈	上位 patch のみ
Original PatchCore	×	×	×
global coreset	×	×	×
層化 coreset 単独	○	×	×
graph 単独・全 patch	×	○	×
graph 単独・疎推論	×	○	○
提案統合手法	○	○	○

比較時は backbone, 入力解像度, 特徴層, bank 総数, 特徴次元, 閾値決定法を固定する.

9 成功基準

以下は研究開始時の暫定 gate であり, 現場タクトタイムと許容 FPR の確認後に更新する.

- 同じ memory bank 容量で Image AP が baseline 以上である.
- Pixel AP または AUPRO を 3 ポイント以上改善する, または同等精度で 2 倍以上高速化する.
- worst-mode FPR および FP/1000 good を baseline 比 30% 以上削減する.
- chip Recall を低下させない.
- CPU end-to-end p95 を中期的に 100 ms/image 以下へ近づける.
- 疎 graph 追加時間を総推論時間の 20% 以下にする.

10 研究ロードマップ

- Phase 0: 現場制約, データ ID, group-aware split, GT 版を固定する.
- Phase 1: Original PatchCore と SaikuPatchCore baseline を再現する.

3. Phase 2：正常モードの存在，安定性，global coreset の coverage を検証する．
4. Phase 3：層化 coreset 単独を同一 bank 予算で評価する．
5. Phase 4：graph 単独を Laplacian，GraphSAGE，GAT の順に評価する．
6. Phase 5：層化 coreset と疎 graph を統合し，Pareto 評価を行う．
7. Phase 6：IPCA，ANN，単一解像度，軽量 backbone，ONNX/OpenVINO 等を評価する．
8. Phase 7：KHI 設備間転移および公開金属データへ展開する．

11 想定される貢献と限界

学術的貢献は，同一製品内の rare normal を保護する bank 設計，query-selective な疎 graph 文脈推論，accuracy–latency–memory–worst-mode fairness の同時評価にある．工場導入上は，重い bank 構築を offline へ分離し，online 側を ROI，CNN，ANN，必要時 graph に限定する．

限界として，KHI 異常画像数が少ないこと，正常モード定義がデータ依存となり得ること，GNN が微小異常を平滑化する危険があることを明記する．これらには公開データ併用，cluster stability 評価，1–2 層の浅い graph，残差融合，異常サイズ別評価で対処する．

参考文献

- [1] K. Roth et al., “Towards Total Recall in Industrial Anomaly Detection,” CVPR, 2022.
- [2] X. Jiang et al., “SoftPatch: Unsupervised Anomaly Detection with Noisy Data,” NeurIPS, 2022.
- [3] J. Bae et al., “PNI: Industrial Anomaly Detection using Position and Neighborhood Information,” ICCV, 2023.
- [4] K. Batzner et al., “EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies,” WACV, 2024.
- [5] J. Jung et al., “TailedCore: Few-Shot Sampling for Unsupervised Long-Tail Noisy Anomaly Detection,” CVPR, 2025.
- [6] W. Hamilton et al., “Inductive Representation Learning on Large Graphs,” NeurIPS, 2017.
- [7] P. Veličković et al., “Graph Attention Networks,” ICLR, 2018.