

先行研究整理

PatchCore 改良・long-tail normality・GNN・高速化

対象研究： オートリベッタ穿孔後の切粉・異物検知

基盤手法： PatchCore / SaikuPatchCore

文書版： v2.0

作成日： 2026 年 8 月 5 日

目次

1	整理方針	2
2	PatchCore と memory bank 系手法	2
2.1	PatchCore	2
2.2	SoftPatch	2
2.3	TailedCore	2
3	位置・近傍・関係性を利用する研究	2
3.1	PNI	2
3.2	Vision GNN・GraphSAGE・GAT	2
4	特徴適応・foundation model 系	3
4.1	ReConPatch	3
4.2	AnomalyDINO と Dinomaly	3
4.3	DFM	3
5	高速・省資源異常検知	3
5.1	EfficientAD	4
5.2	次元削減と ANN	4
6	現実的データ条件と評価	4
6.1	MVTec AD から MVTec AD 2 へ	4
6.2	Real-IAD・MPDD	4
7	主要先行研究の比較	4
8	研究 gap	5
9	査読で求められる実験	6
10	本研究での採用優先度	6

1 整理方針

本資料は、本研究の新規性を明確にするため、PatchCore 系異常検知を「特徴抽出」「memory bank」「位置・関係性」「高速化」「現実的データ条件」の観点から整理するものである。査読済み国際会議・ジャーナルを優先し、preprint は将来候補として区別する。

2 PatchCore と memory bank 系手法

2.1 PatchCore

PatchCore は、ImageNet 事前学習 CNN の中間特徴を局所 patch として抽出し、正常特徴の代表集合を coreset として保持する。推論時は query patch と memory bank の最近傍距離を用いる。学習を必要とせず、高い局在性能を示した点が重要である。一方、bank の代表性、データ量増加時の容量、位置関係の弱さが改良対象となる。

2.2 SoftPatch

SoftPatch は、正常学習データへ異常・外れ値が混入する条件を扱い、patch-level outlier score に基づいて bank を浄化・重み付けする。本研究の課題は「異常混入の除去」ではなく「稀だが正常な mode の保護」であり、方向性は異なる。ただし、normal mode を誤って外れ値として除外しない設計を考える上で重要な比較対象である。

2.3 TailedCore

TailedCore は、long-tail かつ noisy な multi-class 異常検知条件における few-shot sampling を扱う。少数クラスの代表性を補う考え方は、本研究の層化 coreset に近い。差別化点は、本研究が製品クラス間ではなく、同一金属製品内の明度・反射・設備・位置などの正常モード不均衡を対象とする点である。

3 位置・近傍・関係性を利用する研究

3.1 PNI

PNI は、位置情報と近傍情報を工業異常検知へ導入する。したがって、単に patch 座標を特徴へ加える、または周辺 patch を参照するだけでは新規性が弱い。本研究では、層化 bank 内の mode 属性、極座標周期境界、query-selective な疎 graph を統合する必要がある。

3.2 Vision GNN・GraphSAGE・GAT

Vision GNN 系は画像 patch を node として扱う一般的枠組みを示している。GraphSAGE は近傍 sample と aggregation による inductive 表現学習を行い、新しい query node を扱いやすい。GAT は

近傍ごとの重要度を attention で学習できる．一方，全 patch graph は計算量が大きく，微小異常を周辺特徴で平滑化する危険がある．

表 1: graph 方式の比較

方式	長所	本研究での位置づけ
Graph Laplacian	学習不要で関係的不整合を計算可能	最初の graph baseline
GCN	実装が単純	全 patch 平滑化に注意
GraphSAGE	inductive, 近傍 sample 可能	疎 graph の第一候補
GAT	重要な近傍を選択可能	速度・安定性確認後の候補
GIN	高い表現力	初期検証後の追加候補

4 特徴適応・foundation model 系

4.1 ReConPatch

ReConPatch は，事前学習特徴を対象 domain へ適応させることで，patch 表現の識別性を改善する．これは固定 backbone 特徴をそのまま使う PatchCore の弱点を補う方向である．本研究では，まず bank 構築と graph の効果を固定 backbone 上で確認し，その後の追加比較とする．

4.2 AnomalyDINO と Dinomaly

AnomalyDINO は DINOv2 特徴を few-shot anomaly detection へ利用し，少数正常画像でも強い表現を得る方向を示す．Dinomaly は multi-class unsupervised anomaly detection を簡潔な Transformer 構成で扱う．これらは backbone 表現の強化に関する研究であり，本研究の bank allocation や sparse graph とは直交する．したがって，将来の backbone 差し替え候補であるが，v1 baseline 安定前には導入しない．

4.3 DFM

DFM は feature matching を微分可能な形で統合し，feature extraction と matching を end-to-end に最適化する．異常ラベルや GT を使って特徴を学習するだけでは新規ではないことを示す重要な比較対象である．本研究が教師あり adapter へ進む場合は，one-class 一般化を維持する新しい制約が必要である．

5 高速・省資源異常検知

5.1 EfficientAD

EfficientAD は millisecond-level latency を中心的な研究課題として扱い、軽量 teacher-student 構成で高速な異常検知を実現する。高速化論文では、精度だけでなく、入力解像度、batch size、device、warm-up、前後処理、p95 latency、memory を明示する必要があることを示す。

5.2 次元削減と ANN

PatchCore の memory bank 容量は特徴数 N と次元 d に概ね比例する。PCA/IPCA、coreset、HNSW、FAISS IVF/PQ は独立した高速化要素である。ただし、t-SNE や UMAP は可視化には有用でも、距離構造を変えるため主推論空間へ直接用いる場合は慎重が必要である。

$$\text{Memory} \simeq 4Nd, \quad \text{Memory}_{\text{compressed}} \simeq 4pNk, \quad (1)$$

ここで p は coreset 率、 k は削減後次元である。

6 現実的データ条件と評価

6.1 MVTec AD から MVTec AD 2 へ

MVTec AD は工業異常検知の標準 benchmark であるが、近年は性能飽和が指摘される。MVTec AD 2 は照明変化、高分散正常外観、微小欠陥など、より難しい条件を含む。本研究の正常モード保存と微小局所在り方を評価する上で重要である。

6.2 Real-IAD・MPDD

Real-IAD は multi-view かつ大規模な実工業条件を扱う。MPDD は金属部品を中心とするため、KHI 以外の金属製品への一般化評価に適している。全量評価が重い場合は、金属系カテゴリを事前登録して段階的に実施する。

7 主要先行研究の比較

手法	年・会議	主な貢献	本研究との差・利用方法
PatchCore	2022 CVPR	coreset memory bank と最近傍 patch matching	baseline. bank 代表性と関係性を改良対象とする
SoftPatch	2022 NeurIPS	noisy normal data への頑健化	異常除去ではなく rare normal 保護へ焦点を移す

PNI	2023 ICCV	位置・近傍情報の利用	単純な位置付与との差別化が必要
EfficientAD	2024 WACV	高精度・低遅延	工場速度評価の比較基準
ReConPatch	2024 WACV	patch 特徴の domain 適応	backbone 適応の比較候補
AnomalyDINO	2025 WACV	DINOv2 few-shot 特徴	v2 以降の backbone 候補
TailedCore	2025 CVPR	long-tail noisy 条件の sampling	class 間ではなく同一製品内 mode 不均衡を扱う
Dinomaly	2025 CVPR	multi-class unsupervised AD	簡潔な統一モデルとの比較候補
DFM	2025 CVPR	differentiable feature matching	教師あり特徴学習との差別化に必要

8 研究 gap

既存研究から、以下は単独では新規性になりにくい。

- PatchCore へ PCA, HNSW, FAISS, GNN を追加するだけ。
- DINOv2 へ backbone を置き換えるだけ。
- 正常・異常 GT で CNN を fine-tuning するだけ。
- 極座標位置を特徴へ加えるだけ。

本研究の gap は、次の三点を一つの問題設定として扱うことである。

1. 同一製品内の rare normal mode を bank 圧縮時に保護する。
2. mode 属性を持つ prototype graph と query patch の関係的不整合を使う。
3. 全 patch ではなく疑わしい patch だけを再評価し、工場速度を維持する。




図 1: 先行研究群と本研究の位置づけ

9 査読で求められる実験

- Original PatchCore, global coreset, 層化 coreset, graph 単独, 統合手法のアブレーション.
- 同一 bank 数・同一特徴次元・同一 backbone での公平比較.
- Image AUROC だけでなく Pixel AP, AUPRO, FP/1000, worst-mode FPR.
- KHI #6, #7, 設備間転移, 公開金属データでの評価.
- 3 seed 以上, 信頼区間, FP/FN 代表画像, 異常サイズ別評価.
- end-to-end p50/p95/p99, RAM, bank/index 容量, 実行環境.

10 本研究での採用優先度

表 3: 先行研究要素の導入順序

優先度	要素	理由
A	PatchCore baseline・global coreset	新規要素の効果測定に必須
A	正常モード解析・層化 coreset	研究仮説の中心
A	Graph Laplacian / 1 層 GraphSAGE	軽量な関係性評価
A	p95 latency・bank 容量	工場導入軸
B	IPCA・HNSW・ONNX/OpenVINO	提案効果確認後の軽量化
C	DINOv2・GAT・IVFPQ	baseline 安定後の拡張

参考文献

- [1] K. Roth et al., “Towards Total Recall in Industrial Anomaly Detection,” CVPR, 2022.
- [2] X. Jiang et al., “SoftPatch: Unsupervised Anomaly Detection with Noisy Data,” NeurIPS, 2022.
- [3] J. Bae et al., “PNI: Industrial Anomaly Detection using Position and Neighborhood Information,” ICCV, 2023.
- [4] K. Batzner et al., “EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies,” WACV, 2024.
- [5] H. Hyun et al., “ReConPatch: Contrastive Patch Representation Learning for Industrial

- Anomaly Detection,” WACV, 2024.
- [6] T. Damm et al., “AnomalyDINO: Boosting Patch-Based Few-Shot Anomaly Detection with DINOv2,” WACV, 2025.
 - [7] J. Jung et al., “TailedCore: Few-Shot Sampling for Unsupervised Long-Tail Noisy Anomaly Detection,” CVPR, 2025.
 - [8] Y. Guo et al., “Dinomaly: The Less Is More Philosophy in Multi-Class Unsupervised Anomaly Detection,” CVPR, 2025.
 - [9] J. Wu et al., “DFM: Differentiable Feature Matching for Anomaly Detection,” CVPR, 2025.
 - [10] W. Hamilton et al., “Inductive Representation Learning on Large Graphs,” NeurIPS, 2017.
 - [11] P. Veličković et al., “Graph Attention Networks,” ICLR, 2018.
 - [12] P. Bergmann et al., “MVTec AD – A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection,” CVPR, 2019.